

Actividad. Herramientas en R para análisis exploratorio

Autor: Miguel Ángel Vicente Mesonero

No incluiré en este documento las tareas para las cuales el script de R da respuesta y en la pregunta no pide algo fuera de este.

4. Pega el diagrama de cajas y comenta el resultado.




Figura 1 de los grupos son bastante similares, entre 50 y 60 años.

Observamos en el diagrama de cajas que la población tiene edades comprendidas entre poco menos de 30 años y 90. La mediana en todos los grupos es entre 50 y poco más de 60. Algo llamativo es que los rangos de edad del estadio IV parece más corto, pareciendo un grupo más homogéneo que el resto. Vemos también que no hay apenas pacientes jóvenes (cerca de los 30) ni ancianos (cerca de los 80-90). Tiene sentido real pues la esperanza de vida podría ser menor en pacientes con cáncer más avanzado (IV) y es posible que estadios avanzados de cáncer de mama sean menos comunes en gente tan joven. Dependiendo de la fecha de los datos podríamos pensar también que los programas de cribado han podido mejorar a lo largo del tiempo y eso podría explicar que la edad de detección sea algo menor en estadios previos, antes de que avance la enfermedad.

Estas diferencias podrían ser explicadas por las diferencias de casos en cada grupo, ya que solo tenemos 20 casos en el estadio IV con respecto a más de 150 en cada uno de los demás grupos.

5. Calcula la media de edad de diagnóstico con `tapply()` y pégalo.

```
```R  

tapply(breast_data_stage$age_at_diagnosis,breast_data_stage$stage,mean)

```
```

| | |
|-----------|----------|
| Stage I | 60.02732 |
| Stage II | 57.95987 |
| Stage III | 57.08861 |
| Stage IV | 59.05000 |
| Stage X | 61.85714 |

6. Test de comparación de medias

Los dos vectores no siguen una distribución normal, pero presentan homocedasticidad y hay más de 30 datos. Esto nos deja la opción de usar la *t* de student, pero dejando claro que los datos no siguen una distribución normal. Otra opción es usar la prueba de Wilcoxon, que no requiere una distribución normal.

Yo he probado las dos (figura 2), y en ambas la diferencia es significativa ($p < 0,05$). Si no hubiese sido así hubiera priorizado Wilcoxon, ya que se cumplen los requisitos para su uso ¿Qué significa que la diferencia es significativa? De este resultado podemos concluir que la edad a la que se diagnostica el estadio I y el III es con una gran probabilidad, mayor en aquellos con estadio I. La prueba de Wilcoxon no nos dice cuánto de diferentes, el *t* test nos indica que esa diferencia estaría, con un 95% de confianza, entre 0.07 y 5.8 años, sin embargo, al haberla calculado con datos que no siguen distribución normal podría haber error en esta asunción.

```
> t.test(age_at_diagnosis~stage, data = frame_edad_I_III, var.equal = TRUE)  
  
Two sample t-test  
  
data: age_at_diagnosis by stage  
t = 2.0176, df = 339, p-value = 0.04442  
alternative hypothesis: true difference in means between group Stage I and group Stage  
III is not equal to 0  
95 percent confidence interval:  
 0.07367122 5.80375839  
sample estimates:  
 mean in group Stage I mean in group Stage III  
      60.02732          57.08861  
  
> wilcox.test(age_at_diagnosis~stage, data = frame_edad_I_III)  
  
wilcoxon rank sum test with continuity correction  
  
data: age_at_diagnosis by stage  
W = 16333, p-value = 0.03877  
alternative hypothesis: true location shift is not equal to 0
```

Figura 2. Resultados de *t* test y Wilcoxon test de los datos. Ambos ofrecen significancia estadística ($p < 0.05$)

7. Análisis de supervivencia

De los resultados del análisis de supervivencia observamos que hay una diferencia entre el grupo con pr positivo y el grupo con pr negativo. Hay una significancia estadística ($p=0.01<0.05$) que indica que el valor del receptor de progesterona supone una diferencia en cuanto a supervivencia a favor de aquellos en los cuales el receptor de progesterona es positivo.

Es importante tener en cuenta que hemos eliminado a aquellos pacientes que no tenían determinado el pr, eran un 4,9% de las personas, ¿conocer su PR podría haber cambiado el resultado? Decidí eliminarlos por el escaso número y porque además más del 95% tenían una muerte muy temprana. Posiblemente hubiera empañado el análisis y no hubiera dado ninguna aclaración, pero parece buena idea tener esto en cuenta como una posible crítica y punto de incertidumbre que podría afectar a los resultados, y que podría contrastar en un análisis más profundo.

